

智能仪器设计基础（一）

西安交通大学

主讲人：曾翔君

02

多输入耦合传感器的静态特性及建模

- 传感器对多种环境量都敏感（主环境量和干扰量）
- 可以通过引入其它传感器对干扰量进行测量和补偿
- 多传感器系统存在交叉耦合
- 通过标定实验获得不同输入环境量下多传感器的输出
- 多输入/多输出系统传输特性的拟合称为多元回归技术
- 多元系统的耦合使得高维数学传输函数无法直观确立
- 人工神经网络（ANN）提供了一个通用的模型
- ANN可以利用标定数据自适应学习模型参数

- 选择一个平面或者超平面通过二维或多维空间中的测量点，并使得测量点到平面或超平面的欧式距离最短

对传感器进行标定的数据：
$$\begin{bmatrix} x_{1i} \\ x_{2i} \end{bmatrix} \rightarrow \begin{bmatrix} y_{1i} \\ y_{2i} \end{bmatrix}, \quad i = 1 \dots N$$

期望的多元拟合函数（平面）：
$$\mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \mathbf{W}\mathbf{X} + \mathbf{B} = \begin{bmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$


残差方程：
$$\boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_{1i} \\ \varepsilon_{2i} \end{bmatrix} = \begin{bmatrix} y_{1i} \\ y_{2i} \end{bmatrix} - \left(\begin{bmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \end{bmatrix} \begin{bmatrix} x_{1i} \\ x_{2i} \end{bmatrix} + \begin{bmatrix} b_{1i} \\ b_{2i} \end{bmatrix} \right)$$

代价函数：残差方差最小（欧式距离最短）
$$\begin{cases} J = \sum_{i=1}^N [\varepsilon_{1i}^2 + \varepsilon_{2i}^2] \\ \frac{\partial J}{\partial w_{11}} = 0, \frac{\partial J}{\partial w_{22}} = 0, \frac{\partial J}{\partial b_1} = 0, \frac{\partial J}{\partial b_2} = 0 \end{cases}$$


03

逻辑回归


- 逻辑回归是通过选择合适的分类函数对样本进行分类
- 决策函数把样本分为两类：逻辑1（合格，好）与逻辑0（不合格，坏）
- 通过已知分类的样本来选择最优分类函数称为训练和学习



(a)



(b)




(c)

逻辑回归的几种情况：(a)线性逻辑分类；(b)非线性逻辑分类；(c)过拟合现象



从逻辑回归到人工神经网络 (1)

- 逻辑回归的过程可以通过感知器来描述




单层感知器

线性分类函数: $g(x) = w_1 \cdot x_1 + w_2 \cdot x_2 + b$

激励函数: $f(x) = \text{sign}(x)$

- 符号函数sign不连续且不可微, 故引入其它激励函数



人工神经元


Sigmoid函数: $f(x) = \frac{1}{1 + e^{-x}}$ 导数: $f'(x) = f(x)[1 - f(x)] = \frac{e^{-x}}{(1 + e^{-x})^2}$

tanh函数: $f(x) = \frac{1 - e^{-2x}}{1 + e^{-2x}}$ 导数: $f'(x) = 1 - f^2(x) = \frac{4}{(e^x + e^{-x})^2}$

04

从逻辑回归到人工神经网络 (2)

- 线性分类不能解决基本的逻辑分类问题—异或门
- 多层神经元构成的ANN能够实现非线性分类
- 多层ANN实际上是把样本通过非线性变换，在另外一个空间再进行线性分类



权系数和偏置系数如何计算？

三层人工神经网络

05

误差反向传播 (BP) 算法(1)

- 对训练样本进行学习，选择代价函数最小的一组权系数和偏置
- 平方代价函数（欧式距离最短）：

$$J_{total} = \sum_i^N \frac{1}{2} (\hat{y}_i - y_i)^2$$

- 对数代价函数（最大似然法）

$$J = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

- BP算法的思想是通过初始权系数和偏置来计算样本的输出，将ANN输出 $\hat{y}_i$ 与实际输出 y_i 之间的误差，然后根据利用反向误差修正权系数和偏置系数，反复迭代，最终得到使代价函数达到最小值的一组参数



05

误差反向传播 (BP) 算法(2)

• 算法流程

第一步，计算隐层输出：

$$h_1 = f(z_1) = \text{sigmoid}(w_{11}^{(1)} \cdot x_1 + w_{21}^{(1)} \cdot x_2 + b_1^{(1)})$$

$$h_2 = f(z_2) = \text{sigmoid}(w_{12}^{(1)} \cdot x_1 + w_{22}^{(1)} \cdot x_2 + b_2^{(1)})$$

第二步，正向计算ANN输出：

$$\hat{y} = f(h_1, h_2) = \text{sigmoid}(w_1^{(2)} \cdot h_1 + w_2^{(2)} \cdot h_2 + b^{(2)})$$

第三步，计算输出的代价函数：


$$J_{total} = \sum_i \frac{1}{2} (\hat{y}_i - y_i)^2$$

第四步，计算代价函数对权系数和偏置的偏导数：

$$\frac{\partial J_{total}}{\partial w_{11}^{(1)}} = \sum_i (\hat{y}_i - y_i) \cdot \frac{\partial \hat{y}_i}{w_{11}^{(1)}} = \sum_i (\hat{y}_i - y_i) \cdot \frac{\partial \hat{y}_i}{\partial h_1} \cdot \frac{\partial h_1}{w_{11}^{(1)}} \quad \frac{\partial \hat{y}_i}{\partial h_1} = \frac{e^{-w_1^{(2)} h_1 - w_2^{(2)} h_2 - b^{(2)}}}{[1 + e^{-w_1^{(2)} h_1 - w_2^{(2)} h_2 - b^{(2)}}]^2} \cdot w_1^{(2)} \quad \frac{\partial h_1}{\partial w_{11}^{(1)}} = \frac{e^{-w_{11}^{(1)} x_{1i} - w_{21}^{(1)} x_{2i} - b_1^{(1)}}}{[1 + e^{-w_{11}^{(1)} x_{1i} - w_{21}^{(1)} x_{2i} - b_1^{(1)}}]^2} \cdot x_{1i}$$

第五步，利用梯度下降法对参数进行修正（ η 学习因子）：

$$\hat{\theta} = \theta - \eta \cdot \frac{\partial J}{\partial \theta}$$



基于ANN和BP算法的传感器建模实例(1)

【例】下表给出了一个由位移传感器和温度传感器构成的传感器系统的标定实验数据，不同的位移和温度对两个传感器的输出均存在耦合影响。请利用BP神经网络对该传感器系统的输入/输出特性进行建模。

表2-3 具有温度敏感性的位移传感器的标定实验数据（单位：V）（T：环境温度；S：被测位移）

T(°C) S(mm)	0		20		40		60		80	
	Y _S (V)	Y _T (V)	Y _S (V)	Y _T (V)	Y _S (V)	Y _T (V)	Y _S (V)	Y _T (V)	Y _S (V)	Y _T (V)
0.1	0.36	-1.0	0.48	-1.27	0.84	-1.59	1.44	-1.99	2.28	-2.47
0.2	0.74	-0.8	0.86	-1.07	1.22	-1.39	1.82	-1.79	2.66	-2.27
0.3	1.24	-0.6	1.36	-0.87	1.72	-1.19	2.32	-1.59	3.16	-2.07
0.4	1.86	-0.4	1.98	-0.67	2.34	-0.99	2.94	-1.39	3.78	-1.87
0.5	2.6	-0.2	2.72	-0.47	3.08	-0.79	3.68	-1.19	4.52	-1.67



基于ANN和BP算法的传感器建模实例(2)



建模和计算流程

第一步，利用Matlab工具Newff函数，输入网络参数，建立ANN

三层网络：隐层节点—3，激励函数—tansig;
输出节点—2，激励函数—purlin(线性)

第二步，对输入/输出归一化样本，调用Train函数进行对网络参数进行训练

$$S_N = 2 / (S_{\max} - S_{\min}) \cdot (S - S_{\min}) - 1 \quad Y_S = (Y_{S\max} - Y_{S\min}) / 2 \cdot (Y_{SN} + 1) + Y_{S\min}$$



基于ANN和BP算法的传感器建模实例(3)

第三步，采用BP算法对于实际测量到的神经网络输出来估计输入被测量

ANN正向计算公式：

$$\begin{cases} z_1 = w_{11}^{(1)} \cdot S_N + w_{12}^{(1)} \cdot T_N + b_1^{(1)} \\ z_2 = w_{21}^{(1)} \cdot S_N + w_{22}^{(1)} \cdot T_N + b_2^{(1)} \\ z_3 = w_{31}^{(1)} \cdot S_N + w_{32}^{(1)} \cdot T_N + b_3^{(1)} \end{cases} \quad \begin{cases} h_x = \text{tansig}(z_x) = 2 / (1 + e^{-2z_x}) - 1 \\ \frac{\partial h_x}{\partial z_x} = \frac{4e^{-2z_x}}{(1 + e^{-2z_x})^2} \end{cases}, x = 1, 2, 3$$

$$\begin{cases} Y_{SN} = w_{11}^{(2)} \cdot h_1 + w_{12}^{(2)} \cdot h_2 + w_{13}^{(2)} \cdot h_3 + b_1^{(2)} \\ Y_{TN} = w_{21}^{(2)} \cdot h_1 + w_{22}^{(2)} \cdot h_2 + w_{23}^{(2)} \cdot h_3 + b_2^{(2)} \end{cases}$$

输出到输入之间的偏导数为：

$$\begin{bmatrix} \partial Y_{SN} / \partial S_N \\ \partial Y_{SN} / \partial T_N \\ \partial Y_{TN} / \partial S_N \\ \partial Y_{TN} / \partial T_N \end{bmatrix} = \begin{bmatrix} w_{11}^{(2)} \cdot w_{11}^{(1)} & w_{12}^{(2)} \cdot w_{21}^{(1)} & w_{13}^{(2)} \cdot w_{31}^{(1)} \\ w_{11}^{(2)} \cdot w_{12}^{(1)} & w_{12}^{(2)} \cdot w_{22}^{(1)} & w_{13}^{(2)} \cdot w_{32}^{(1)} \\ w_{21}^{(2)} \cdot w_{11}^{(1)} & w_{22}^{(2)} \cdot w_{21}^{(1)} & w_{23}^{(2)} \cdot w_{31}^{(1)} \\ w_{21}^{(2)} \cdot w_{12}^{(1)} & w_{22}^{(2)} \cdot w_{22}^{(1)} & w_{23}^{(2)} \cdot w_{32}^{(1)} \end{bmatrix} \times \begin{bmatrix} \partial h_1 / \partial z_1 \\ \partial h_2 / \partial z_2 \\ \partial h_3 / \partial z_3 \end{bmatrix}$$

代价函数： $J = \frac{1}{2} [(Y_{SN} - Y_{SN0})^2 + (Y_{TN} - Y_{TN0})^2]$

修正函数：

$$\begin{cases} S_N = S_{N0} - \eta \frac{\partial J}{\partial S_N} = S_{N0} - \eta [(Y_{SN} - Y_{SN0}) \frac{\partial Y_{SN}}{\partial S_N} + (Y_{TN} - Y_{TN0}) \frac{\partial Y_{TN}}{\partial S_N}] \\ T_N = T_{N0} - \eta \frac{\partial J}{\partial T_N} = T_{N0} - \eta [(Y_{SN} - Y_{SN0}) \frac{\partial Y_{SN}}{\partial T_N} + (Y_{TN} - Y_{TN0}) \frac{\partial Y_{TN}}{\partial T_N}] \end{cases}$$





谢谢观看